

Contrôle garanti par réseaux de neurones pour des robots mobiles

Pôle Systèmes Cyber-Physiques

Tarek OMRAN Ali RAMLAOUI

20 avril 2022

Encadré par Adnane SAOUD

Système dynamique

$$F : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^n$$

$$(x(k), u(k)) \mapsto F(x(k), u(k)) = x(k+1)$$

muni d'un contrôleur prenant des décisions sur l'entrée en fonction de l'état $x(k)$

Système dynamique

$$F : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^n$$

$$(x(k), u(k)) \mapsto F(x(k), u(k)) = x(k+1)$$

muni d'un contrôleur prenant des décisions sur l'entrée en fonction de l'état $x(k)$




Schéma bloc du système

Système dynamique

$$F : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^n$$

$$(x(k), u(k)) \mapsto F(x(k), u(k)) = x(k+1)$$

muni d'un contrôleur prenant des décisions sur l'entrée en fonction de l'état $x(k)$




Schéma bloc du système

- Contrôleur : réseau de neurones
- Analyse d'atteignabilité par intervalles
- Images d'intervalles par la fonction F

Définition (Intervalle de dimension n)

Considérons l'espace \mathbb{R}^n , avec $n \in \mathbb{N}^$. Alors un intervalle de dimension n est un ensemble pouvant s'écrire*

$[\underline{a}_1, \overline{a}_1] \times \dots \times [\underline{a}_n, \overline{a}_n]$, où $(\underline{a}_i \leq \overline{a}_i) \in \mathbb{R}^2, \forall i \in \llbracket 1, n \rrbracket$. On notera l'intervalle $[a]$.

Définition (Intervalle de dimension n)

Considérons l'espace \mathbb{R}^n , avec $n \in \mathbb{N}^$. Alors un intervalle de dimension n est un ensemble pouvant s'écrire*

$[\underline{a}_1, \overline{a}_1] \times \dots \times [\underline{a}_n, \overline{a}_n]$, où $(\underline{a}_i \leq \overline{a}_i) \in \mathbb{R}^2, \forall i \in \llbracket 1, n \rrbracket$. On notera l'intervalle $[a]$.

Definition (Sur-approximation par un intervalle)

Pour tout ensemble $\mathcal{H} \subset \mathbb{R}^n$, on appelle $\mathcal{I}_{\mathcal{H}}$, le plus petit intervalle de \mathbb{R}^n tel que $\mathcal{H} \subset \mathcal{I}_{\mathcal{H}}$.

Définition (Intervalle de dimension n)

Considérons l'espace \mathbb{R}^n , avec $n \in \mathbb{N}^*$. Alors un intervalle de dimension n est un ensemble pouvant s'écrire


$[\underline{a}_1, \overline{a}_1] \times \dots \times [\underline{a}_n, \overline{a}_n]$, où $(\underline{a}_i \leq \overline{a}_i) \in \mathbb{R}^2$, $\forall i \in \llbracket 1, n \rrbracket$. On notera l'intervalle $[a]$.

Definition (Sur-approximation par un intervalle)

Pour tout ensemble $\mathcal{H} \subset \mathbb{R}^n$, on appelle $\mathcal{I}_{\mathcal{H}}$, le plus petit intervalle de \mathbb{R}^n tel que $\mathcal{H} \subset \mathcal{I}_{\mathcal{H}}$.


Definition (Longueur d'un intervalle)

$$\rho(\mathcal{I}) = \max_{i \in \llbracket 1, n \rrbracket} (\underline{a}_i - \overline{a}_i)$$




Atteignabilité Système

Atteignabilité




Atteignabilité Système




Atteignabilité contrôleur


Atteignabilité



Atteignabilité Système




Atteignabilité contrôleur




Atteignabilité boucle fermée

Systèmes considérés



Mountain car

Systèmes considérés




Mountain car

$$F : \begin{cases} x(k+1) &= x(k) + v(k+1) \\ v(k+1) &= u(k)P - 0.0025 \cos(3x(k)) \end{cases}$$

où P , constante, $u \in [-1, 1]$, $x \in [-1.2, 0.6]$, position horizontale, et vitesse, $v \in [-0.07, 0.07]$

Systèmes considérés



Mountain car

$$F : \begin{cases} x(k+1) &= x(k) + v(k+1) \\ v(k+1) &= u(k)P - 0.0025 \cos(3x(k)) \end{cases}$$

où P , constante, $u \in [-1, 1]$, $x \in [-1.2, 0.6]$, position horizontale, et vitesse, $v \in [-0.07, 0.07]$


Reward function : Critiquer l'action du contrôleur

$$q(k) = \begin{cases} 100 & \text{si } x(k) \geq 0.6 \\ q(k-1) - 0.1u(k)^2 & \text{sinon} \end{cases}$$

Objectif d'atteignabilité


Exemple classique en Reinforcement Learning

Systemes consideres



Pendule

Systèmes considérés




Pendule

$$F : \begin{cases} \theta(k+1) &= \theta(k) + \delta_t \dot{\theta}(k) \\ \dot{\theta}(k+1) &= \dot{\theta}(k) + \frac{3g\delta_t}{2l} \sin(\theta(k)) + \frac{3}{ml^2} u(k)\delta_t \end{cases}$$

où δ_t, g, l, m , constantes, $u(k) \in [-2, 2]$ et

$$X(k) = \begin{bmatrix} \theta \\ \dot{\theta} \end{bmatrix}, X(k) \in [0, 2\pi] \times [-8, 8]$$



Pendule

$$F : \begin{cases} \theta(k+1) &= \theta(k) + \delta_t \dot{\theta}(k) \\ \dot{\theta}(k+1) &= \dot{\theta}(k) + \frac{3g\delta_t}{2l} \sin(\theta(k)) + \frac{3}{ml^2} u(k) \delta_t \end{cases}$$

où δ_t, g, l, m , constantes, $u(k) \in [-2, 2]$ et

$$X(k) = \begin{bmatrix} \theta \\ \dot{\theta} \end{bmatrix}, X(k) \in [0, 2\pi] \times [-8, 8]$$

Reward function : Critiquer l'action du contrôleur

$$q(k+1) = m(\theta(k))^2 + 0.01\dot{\theta}(k)^2 + 0.001(u(k))^2, \text{ où } \theta(k) \in [-\pi, \pi]$$

où m est la mesure principale de l'angle

Objectif de stabilité

Principe du Deep Reinforcement Learning

- Objectif : maximiser la fonction récompense sur l'ensemble des décisions prises
- Toute itération est représentée par un état s_t , une action a_t , une récompense r_t et un nouvel état s_{t+1}
- Critique d'une action : Récompense à l'instant t + "récompense potentiel" à partir du nouvel état (valeur Q)
$$q_t = r_t + \gamma q_{t+1}, 0 < \gamma < 1$$

Principe du Deep Reinforcement Learning


- Objectif : maximiser la fonction récompense sur l'ensemble des décisions prises
- Toute itération est représentée par un état s_t , une action a_t , une récompense r_t et un nouvel état s_{t+1}
- Critique d'une action : Récompense à l'instant t + "récompense potentiel" à partir du nouvel état (valeur Q)
$$q_t = r_t + \gamma q_{t+1}, 0 < \gamma < 1$$

Il faut introduire un décalage entre le réseau qui renvoie q_t et q_{t+1} pour maintenir la stabilité numérique.

- Introduire des réseaux "target" qui marquent ce décalage (copie décalée des réseaux principaux)
- Implémentation sur TensorFlow et Gym (OpenAI) + parallélisation de la boucle d'entraînement

Deep Deterministic Policy Gradient (DDPG)


Réseau acteur



- C'est le contrôleur
- Couches 1 et 2 : 16 neurones, ReLU
- Couche 3 : 1 neurone, tanh
- Sortie ramenée à l'échelle des actions


Deep Deterministic Policy Gradient (DDPG)

Réseau acteur




- C'est le contrôleur
- Couches 1 et 2 : 16 neurones, ReLU
- Couche 3 : 1 neurone, tanh
- Sortie ramenée à l'échelle des actions

Réseau critique




- Concaténation des états et des actions
- Couches 1 et 2 : 16 neurones, ReLU
- Couche 3 : 1 neurone

Mountain Car - Contrôleur DDPG




Mountain car

Mountain Car - Contrôleur DDPG




Mountain car




Reward sur 200 épisodes


Mountain Car - Contrôleur DDPG



Mountain car




Position de la voiture




Reward sur 200 épisodes


Mountain Car - Contrôleur DDPG




Mountain car



Reward sur 200 épisodes




Position de la voiture



Actions du contrôleur

Pendule - Contrôleur DDPG




Pendule

Pendule - Contrôleur DDPG




Pendule




Reward sur 200 épisodes


Pendule - Contrôleur DDPG



Pendule




Position du pendule




Reward sur 200 épisodes


Pendule - Contrôleur DDPG




Pendule



Reward sur 200 épisodes




Position du pendule



Actions du contrôleur

Atteignabilité du réseau de neurones

- Fonctions d'activation croissantes
- Réseau de neurone Φ à couches denses et L couches intermédiaires
- Paramètres $(n_0, n_1, \dots, n_L) \in \mathbb{N}^{L+1}$, $W^l \in \mathbb{R}^{n_l \times n_{l-1}}$, $b^l \in \mathbb{R}^{n_l}$, $\sigma_l : \mathbb{R}^{n_l} \rightarrow \mathbb{R}^{n_l}$
- Objectif : Image d'un intervalle $[x]$ par le réseau de neurones ?



Atteignabilité du réseau de neurones

- Fonctions d'activation croissantes
- Réseau de neurone Φ à couches denses et L couches intermédiaires
- Paramètres $(n_0, n_1, \dots, n_L) \in \mathbb{N}^{L+1}$, $W^l \in \mathbb{R}^{n_l \times n_{l-1}}$, $b^l \in \mathbb{R}^{n_l}$, $\sigma_l : \mathbb{R}^{n_l} \rightarrow \mathbb{R}^{n_l}$
- Objectif : Image d'un intervalle $[x]$ par le réseau de neurones ?

$$\underline{x}^l = \sigma_l\left(\sum_{j=1}^{n_{l-1}} \underline{p}_{i,j} + b_i^l\right)$$

avec

$$\bar{x}^l = \sigma_l\left(\sum_{j=1}^{n_{l-1}} \bar{p}_{i,j} + b_i^l\right)$$


$$\underline{p}_{i,j} = \begin{cases} w_{i,j}^l \underline{x}_j & \text{si } w_{i,j}^l \geq 0 \\ w_{i,j}^l \bar{x}_j & \text{si } w_{i,j}^l < 0 \end{cases}$$
$$\bar{p}_{i,j} = \begin{cases} w_{i,j}^l \bar{x}_j & \text{si } w_{i,j}^l \geq 0 \\ w_{i,j}^l \underline{x}_j & \text{si } w_{i,j}^l < 0 \end{cases}$$

Principe de l'algorithme d'atteignabilité

- Sur-approximation de l'image réelle en utilisant les formules
- L'erreur de sur-approximation diminue avec la taille des intervalles considérés
- Idée : Partitionner l'intervalle de départ en sous-intervalles permettant de garantir une erreur inférieure à δ fixé

Principe de l'algorithme d'atteignabilité


- Sur-approximation de l'image réelle en utilisant les formules
- L'erreur de sur-approximation diminue avec la taille des intervalles considérés
- Idée : Partitionner l'intervalle de départ en sous-intervalles permettant de garantir une erreur inférieure à δ fixé




Intervalle de départ avec $\epsilon = 0.0001$

Principe de l'algorithme d'atteignabilité

- Sur-approximation de l'image réelle en utilisant les formules
- L'erreur de sur-approximation diminue avec la taille des intervalles considérés
- Idée : Partitionner l'intervalle de départ en sous-intervalles permettant de garantir une erreur inférieure à δ fixé




Intervalle de départ avec $\epsilon = 0.0001$




Contrôle du découpage

Résultats obtenus




Mountain car - Intervalle large

Résultats obtenus




Mountain car - Petit Intervalle

Résultats obtenus





Mountain car - $\epsilon = 0.001$

Résultats obtenus



Mountain car - $\epsilon = 0.0001$


Résultats obtenus



Atteignabilité du contrôleur du pendule

Atteignabilité du système dynamique

- Faire de l'arithmétique d'intervalles
- Remplacer les opérations de la dynamique F par des opérations sur des intervalles



- Faire de l'arithmétique d'intervalles
- Remplacer les opérations de la dynamique F par des opérations sur des intervalles

Exemples

$$[\underline{x}, \bar{x}]^{-1} = \begin{cases} [-\infty, \infty] & \text{si } \underline{x} < 0 \text{ et } \bar{x} > 0 \\ [-\infty, \frac{1}{\underline{x}}] & \text{si } \bar{x} = 0 \\ [\frac{1}{\bar{x}}, \infty] & \text{si } \underline{x} = 0 \\ [\frac{1}{\bar{x}}, \frac{1}{\underline{x}}] & \text{si } \underline{x}\bar{x} > 0 \\ \emptyset & \text{si } \underline{x} = \bar{x} = 0 \end{cases}$$

Atteignabilité du système dynamique


- Faire de l'arithmétique d'intervalles
- Remplacer les opérations de la dynamique F par des opérations sur des intervalles

Exemples


$$[\underline{x}, \bar{x}]^{-1} = \begin{cases} [-\infty, \infty] & \text{si } \underline{x} < 0 \text{ et } \bar{x} > 0 \\ [-\infty, \frac{1}{\underline{x}}] & \text{si } \bar{x} = 0 \\ [\frac{1}{\bar{x}}, \infty] & \text{si } \underline{x} = 0 \\ [\frac{1}{\bar{x}}, \frac{1}{\underline{x}}] & \text{si } \underline{x}\bar{x} > 0 \\ \emptyset & \text{si } \underline{x} = \bar{x} = 0 \end{cases}$$

$$\cos([\underline{x}, \bar{x}]) = [\underline{a}, \bar{a}], \text{ où } \underline{a} = \begin{cases} -1 & \text{si } \exists k \in \mathbb{Z} | (2k\pi + \pi) \in [\underline{x}, \bar{x}] \\ \min(\cos(\underline{a}), \cos(\bar{a})) & \text{sinon} \end{cases}$$
$$\bar{a} = \begin{cases} 1 & \text{si } \exists k \in \mathbb{Z} | (2k\pi) \in [\underline{x}, \bar{x}] \\ \max(\cos(\underline{a}), \cos(\bar{a})) & \text{sinon} \end{cases}$$

Résultats obtenus




Mountain car sur une itération




Pendule sur une itération

Contrôle garanti


- Objectif : Montrer que le système vérifie une spécification S
- Itérer les algorithmes précédents pour estimer les ensembles atteignables au bout de k itérations et simuler le système en boucle fermée



Mountain Car




$$x(0) \in [-0.48, -0.4795], \dot{x}(0) \in [0.01, 0.0101]$$



$$x(0) \in [-0.48, -0.475], \dot{x}(0) \in [0.01, 0.0101]$$


Pendule



Intervalle très petit







Conclusion et Perspectives

- Généraliser la preuve de mountain car a tout l'intervalle de départ
- Utiliser de nouvelles méthodes d'atteignabilité de systèmes contrôlés par des réseaux de neurones (approche ReLUVal, conditions de continuité de l'acteur DDPG...)
- Approcher un Model Predictive Control (MPC) par un réseau de neurones pour le contrôle du système



MPC - Principe

Références

-  Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra.
Continuous control with deep reinforcement learning, 2015.
-  Weiming Xiang, Hoang-Dung Tran, Xiaodong Yang, and Taylor T. Johnson.
Reachable set estimation for neural network control systems : A simulation-guided approach, 2020.
-  P.J. Meyer, A. Devonport, and M. Arcak.
Interval Reachability Analysis : Bounding Trajectories of Uncertain Systems with Boxes for Control and Verification.
SpringerBriefs in Electrical and Computer Engineering. 2021.
-  Greg Brockman, Vicki Cheung, Ludwig Pettersson, Jonas Schneider, John Schulman, Jie Tang, and Wojciech Zaremba.
Openai gym, 2016.
-  Thierry Lecomte, Thierry Servat, and Guilhem Pouzancre.
Formal methods in safety-critical railway systems.
08 2007.
-  Anthony Corso and Mykel J. Kochenderfer.
Interpretable safety validation for autonomous vehicles.
CoRR, 2020.